Hecatonchires manual

Chenxi Qiu

- 这篇文章是提供给*Hecatonchires*开发人员的开发指南。
- *Email:qiucxnju@gmail.com*

CONTENTS

1 HECATONCHIRES简介

1.1 用途

Hecatonchires是metis项目的一个子项目，这个项目是用java编写的，主要用于解决metis中实时排名产生大量计算任务的问题。Hecatonchires是一个采用Master/Slave架构的分布式计算程序。

运行时，在服务器上运行一个叫MasterNode的线程，而在若干个client上分别运行一个SlaveNode线程。MasterNode主要负责：管理所有的slave，包括身份验证、ip管理、心跳管理、查找任务、分配任务。当client的SlaveNode启动后，它需要等待Master分配给他任务，完成任务后把结果发给服务器。并且在这过程中，slave要每隔一段时间发送一个心跳给master，以保证master知道哪些slave在等待，而哪些slave已经关闭。

1.2 SlaveNode原理

SlaveNode的结构比较简单，他主要包含两个线程TaskListener和HeartBeatSender。当启动的时候，SlaveNode会首先自动给Master发送注册请求，接着创建TaskListener和HeartBeatSender。

HeartBeatSender负责每隔一段时间，跟Master做一次心跳以确认双方的信息是否正确。如果HeartBeatSender获得Master通知发现双方存在不一致问题，则会强行终止SlaveNode。

TaskListener会开启一个ServerSocket监听Master发给他的信息，一旦接受了Master的任务，TaskListener会马上开始进行处理，完成后上传结果给服务器。这里TaskListener是但线程的，所以他在处理这个任务的时候是无法监听到任何socket，而这也是不应该发生的。

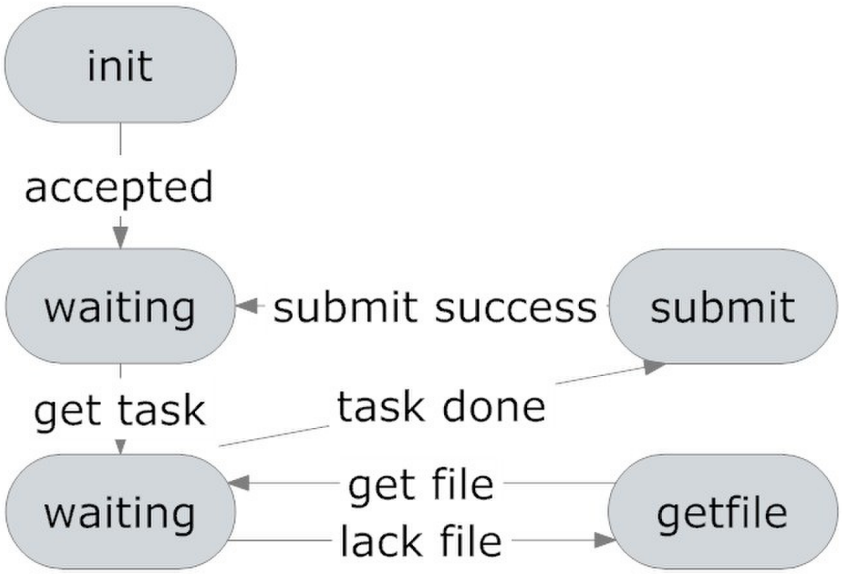

如上图所示，slave首先处于init状态，当slave成功调用register后，进入waiting状态，当TaskListener接收到master的任务后，进入working状态。working的原理是把task需要的文件放入一个安全的目录中并调用shell指令make。如果发现slave缺少这些文件，会进入getfile状态，向master请求文件，当该文件请求到后，继续working。当评测结束后，进入submit状态向master上传文件。当所有文件上传后，report给master告诉master这个任务处理完成了，然后进入waiting状态。

1.3 MasterNode原理

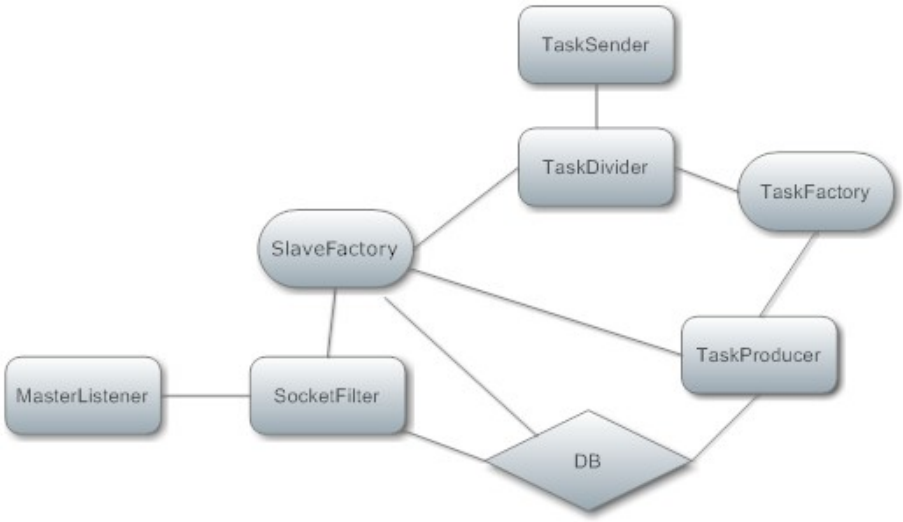

MasterNode的整体结构如上图所示。其中方框代表一类线程，圆圈代表一个数据结构，菱形代表数据库。

其中，所有的Slave的信息都存储在SlaveFacltory，这些信息包括ip地址、认证id、id级别(id级别请参照后面章节的介绍)、心跳时间等，并由其统一提供接口进行访问。所有的任务的信息保存在TaskFactory中，包括评测优先级和传输内容等等。SlaveFactory的所有的函数都是串行的，以维持数据的一致性。所以若非必要，应该尽量减少对其函数的调用次数，TaskFactory与之相同。

MasterListener主要是管理一个ServerSocket，这个ServerSocket固定监听一个接口（接口号请参照“参数设置”章节)。当监听到一个Socket请求后，MasterListener将创建SocketFilter线程，并将这个socket交给SocketFilter线程来处理。

SocketFilter主要是根据Socket中的信息来确定不同的通信请求，包括注册请求、心跳确认、文件接收、文件下载、结果上传五种，其中，注册请求、心跳确认、结果上传三种都需要调用SlaveFactory的接口而结果上传需要调用数据库。

TaskProducer主要是用于产生任务并把它放入TaskFactory中。TaskProducer工作时首先会查看SlaveFtory中是否有需要被回收的任务，如果有，则把他们全部回收，然后查看数据库，看数据库中是否有任务需要评测并且之前没有被TaskProducer侦测到。然后把他们插入TaskFactory中。

TaskDivider用于把任务分发给正在等待任务的slave。首先，TaskDivider会从TaskFactory中提取一个Task，然后查看SlaveFactory，并获取到这个SlaveFactory的ip地址，接着其会创建一个TaskSender的线程将这个task和ip地址转交给TaskSender。

TaskSender把task对应的数据发送给处理这个task的id。

2 通信协议

slave向master发起的通信包括：注册、心跳、文件请求、上传文件、评测结束五种。其中，除了注册是SlaveNode发送给SocketFilter的以外，其他都是TaskListener发送给SocketFilter的。master向slave发起的通信直接是分派任务，是TaskDivider发送给TaskListener的。

slave发送给master的通信第一行包含一个type参数，其中type的取值为：{TYPE_REGISTER, TYPE_HEARTBEAT, TYPE_GETFILE, TYPE_SUBMIT, TYPE_CLOSE}。（具体数值定义在Param中）

当type为TYPE_REGISTER时，说明当前slave是要进行注册，包内第二行和第三行分别是注册的用户名和密码。如果注册成功，返回"OK"，否则，返回"Error"。

当type为TYPE_HEARTBEAT时，说明slave要进行一次心跳。包只有一行也就是type信息，master会检查是否有对应ip的注册信息，如果成功heartbeat，返回"OK"，否则返回"Error"。

当type为TYPE_GETFILE时，slave要读取文件。第二行包含需要读取的文件名。master会返回整个文件。

当type为TYPE_SUBMIT时，slave向master上传文件。第二行是文件名。后面有若干行，每一行以0或者1结尾，1代表不是结尾，0代表是结尾。当发现某行最后为0时，表示传输完成，返回"OK"。

当type为TYPE_CLOSE时，说明评测结束，将调用report函数把结果存入数据库，并且把slave的状态从“工作中”切换到“等待中”。

而分配任务的时候，包的第一行有两个数字a，b，分别代表输入文件个数和输出文件个数。接下来有$a+b$行，从2到$1+a$行，每行两个字符串，以空格分开，分别表示其真实目录位置和评测时重命名的名字。从$2+a$行到$1+a+b$行，每行有两个字符串，以空格分开，分别表示其在评测时的名字和其存放到master后的名字。其中，第$2+a$行必须是themis的输出文件。

3 数据结构

3.1 SlaveInfo

3.1.1 overview

SlaveInfo类用来存储每个slave的信息，其内容如下：
String ip：标示这个slave的ip地址。
String id：标示这个slave认证使用的用户名。
int level：标示这个slave的优先等级，level越低将越先获取任务。
int state：标示这个slave的状态，状态定义在Param中。
long lastHeartBeat：标示这个slave的上一次心跳时间。
int index：标示这个slave加入等待序列的顺序号，当level相同时，index越低将越先获取任务。
TaskInfo taskInfo：保存这个slave正在处理的任务的信息。

3.1.2 构造函数

SlaveInfo(String Ip, String Id, String Password, int Level, int Index)
state被初始化为Param.STATE_WAITING
taskInfo被初始化为null
lastHeartBeat使用SlaveInfo.getTime()得到。

3.1.3 公有函数

long getTime()
获取当前时间

boolean isTimeOut()
返回是否超时

3.2 SlaveFactory

3.2.1 overview

SlaveFactory类用来储存并管理所有slave的信息。

3.2.2 构造函数

SlaveFactory()
产生一个新的SlaveFactory

3.2.3 公有函数

boolean heartBeat(String ip)

ip标示的Slave进行了一次心跳，若这个slave存在在这个SlaveFactory中则更新这个slave的上一次心跳的时间并返回true，反之返回false。

TaskInfo getTask(String ip)

返回ip标示的slave正在处理的任务信息，不存在slave或者这个slave没有在工作，返回null。

boolean setUnwork(String ip)

把ip标示的slave的状态设置为“等待中”，清空其正在处理的TaskInfo信息然后把它让入等待队列中。如果不存在slave或者其状态不是“工作中”，则返回false，否则返回true。

boolean setWork(String ip, TaskInfo taskInfo)

把ip对应的slave的状态设置为工作中，若这个slave不在则直接返回false，如果这个slave的状态不是“调度中”，则将把这个slave删除并返回false。如果正常，则把slave设置为工作中并把这个taskInfo存在这个slave对应的SlaveInfo中并返回true。

String getSlave()

返回一个有效的slave对应的ip。该函数首先把所有等待中的slave按照¡level,index¿（参照SlaveInfo的定义）的顺序排序，并从小到大检查所有的slave如果发现最小的slave出现超时的情况，则将删除这个slave的信息并检查下一个。当找到一个满足条件地slave后，把它的状态设置为“调度中”，把它从等待队列中删除，返回ip。如果不存在这样的slave则返回null。

boolean register(String ip, String id, String password)

向SlaveFactory中注册一个slave。参数分别为其ip，认证id，认证密码。这时将检查数据库，如果这个id和密码不匹配，返回false。否则如果这个ip之前注册过，则先调用remove(ip)删除这个ip对应的slave信息。接着把这个slave新的信息插入SlaveFactory中。

void recycle(Stack¡TaskInfo¿ tasks)

回收所有处理失败的TaskInfo并存储在tasks中。

3.2.4 私有函数

int getLevel(String id, String password)

获取id对应的账户的用户等级，如果账号密码匹配失败则返回-1。

void insert(String ip, SlaveInfo slaveInfo)

向数据结构中插入这个SlaveInfo的信息，这里并不会检查SlaveInfo的正确性，所以插入前请保证这个SlaveInfo的state为“等待中”。若数据结构中已经存在ip则直接退出。

void remove(String ip)

从数据结构中删除ip对应的slave的信息。如果ip不存在则直接退出。如果这个ip正在工作，则把这个ip正在处理的任务存放在回收站中；如果这二个ip正在等待，则从等待队列中删除。

3.3 TaskInfo

3.3.1 overview

TaskInfo保存评测需要的信息:

String data: 存储这个任务所需要传输给slave的数据。

int level: 存储这个任务的评测等级。

int index: 存储这个任务加入等待序列的时间。

TaskInfo是有序的，首先按照level排序，如果level相同则按index排序，所以必须至少保证index是单调递增的，如果index重复可能导致TaskInfo从TaskFactory中丢失。

3.3.2 构造函数

TaskInfo(int Level, int Index, String Data)

3.4 TaskFactory

3.4.1 overview

TaskFactory保存所有的TaskInfo，并把他们按照一颗树来组织。必须保证TaskInfo是两两不同的。并且这个TaskFactory的大小是有限制的，具体限制定义在Param中。

3.4.2 构造函数

TaskFactory()

清空整个数据结构，并把index设置为0，并用这个单调增加的数来构造TaskInfo的序。因为index的序是有限的，只能所以如果index自由增大到一定量，服务器必须重启，但是可以保证的是如果服务器客户端正常，index是不会达到上限的。

3.4.3 公有函数

int getSize()

返回TaskFactory中有多少任务在排队。

int getNeedSize()

返回TaskFactory中还可以插入多少任务。

boolean insert(TaskInfo taskInfo)

像TaskFactory中插入一个TaskInfo，如果TaskFactory已经满了，则返回false并停止向队列中加入这个任务，反之则把任务加入等待序列并返回true。注意这个TaskInfo的index将会被重新设置。

TaskInfo getTask()

函数返回一个正在排队中任务，并将其从等待队列中删除。如果等待队列为空，则返回null，否则返回队列中第一个任务。

4 服务器运行的线程

4.1 MasterNode

4.1.1 overview

MasterNode类负责启动、管理、关闭服务器上的线程。

4.1.2 构造函数

MasterNode()
初始化MasterNode，创建SlaveFactory、TaskFactory两个数据结构和MasterListener、TaskProducer、TaskDivider三个线程。

4.1.3 公有函数

void SetStopFlag()
把MasterNode的StopFlag设置为false并对其管理的所有的线程调用void SetStopFlag()。

void run()
，运行MasterListener、TaskProducer、TaskDivider线程。

4.2 MasterListener

4.2.1 overview

MasterListener用于监控指定的port（定义在Param中），每收到一个socket请求，就创建一个SocketFilter线程处理这个socket。所以当突然有大量socket请求时系统可能因为创建太多的线程而崩溃，所以现在的解决方法是让SocketFilter这个线程的生存周期尽量短。这是在后来的工作中需要被改进的。

4.2.2 构造函数

MasterListener(SlaveFactory s, MasterNode m)
通过传递SlaveFactory和MasterNode来构造这个类，并且试图绑定ServerSocket，如果绑定失败，则调用MasterNode的SetStopFlag()函数。

4.2.3 公有函数

void SetStopFlag()
把StopFlag设置为true。

void run()
循环忙等待socket请求，当收到一个socket请求后，创建SocketFilter线程来处理这个socket请求。如果这时返现StopFlag已经被设置为false了，则退出，否则继续忙等待。所以即使StopFlag被设置为false，这个线程也不会马上停止，只会在收到socket请求后才会停止。

4.3 SocketFilter

4.3.1 overview

SocketFilter是用于处理socket请求的类，它现在采用的是block的通信机制，所以需要保证slave及时发送数据，任何通信一致性上的问题都可能导致这个线程死掉，所以这个线程处理是Master上最脆弱的一环。这时在后面的工作中需要优化的。

4.3.2 构造函数

SocketFilter(Socket s, SlaveFactory sf, MasterNode m)
SocketFilter通过传递socket，SlaveFactory，MasterNode来初始化。

4.3.3 公有函数

void run()
首先SocketFilter会读取Socket信息中的type类型，如果发现是REGISTER，说明一个新的slave到master注册，调用SlaveFactory的register函数，以注册一个新的Slave。如果是HEARTBEAT则调用slaveFactory的heartBeat函数更新这个ip的心跳信息，防止这个ip对应的slave因为过期被回收。如果是GETFILE说明slave缺少文件，读取文件本地文件发送过去。如果是SUBMIT，接收slave发送过来的文件并保存在指定位置。如果是CLOSE，说明一个slave评测完成，保存结果到数据库，这里需要调用report函数，这个还没有实现。

4.4 TaskProducer

4.4.1 overview

TaskProducer的作用是向TaskFactory中插入TaskInfo。TaskProducer会优先回收处理失败并保存在SlaveFactory中的TaskInfo，如果回收过后TaskFactory仍然没满，则访问数据库，从数据库中提取任务。

4.4.2 构造函数

TaskProducer(MasterNode m, SlaveFactory s, TaskFactory t)
TaskProducer通过传递TaskFactory，SlaveFactory，MasterNode来初始化。

4.4.3 公有函数

void GetTaskFromDB(Stack¡TaskInfo¿ tasks, int need)
从数据库中提取不多于need个任务，并保存在tasks中。在这里并没有实现。

void run()
循环运行，直到StopFlag被设置为true。每次循环会从SlaveFactory中回收TaskInfo，并把他们插入TaskFactory中，如果插入完成过后TaskFactory依然未满，则从数据库中提取任务加入TaskFactory中。每次循环结束后，sleep一段时间。

4.5 TaskDivider

4.5.1 overview

TaskDivider是负责任务分发的。这里暂时保证只有一个TaskDivider。

4.5.2 构造函数

TaskDivider(MasterNode m, SlaveFactory s, TaskFactory t)
TaskDivider通过传递TaskFactory，SlaveFactory，MasterNode来初始化。

4.5.3 公有函数

setStopFlag()
将线程的停止标记设置为true。

void SendTask(String ip, TaskInfo taskInfo)
将任务的数据发给对应ip。

void run()
首先从SlaveFactory中提取一个空闲的ip，如果有，则再提取一个任务。如果ip和任务都提取成功，则SalveFactory里面把对应IP设置为工作中，初始化一个TaskSender线程发送。否则，说明SlaveFactory或者TaskFactory为空，则等待一段时间防止占用这两个数据结构的时间。

5 客户端运行的线程

5.1 SlaveNode

5.1.1 overview

SlaveNode类负责启动、管理、关闭客户端上的线程。

5.1.2 构造函数

MasterNode()
初始化SlaveNode。

5.1.3 私有函数

boolean Register()
向master注册，如果注册成功，返回true，否则，返回false。

5.1.4 公有函数

void SetStopFlag()
把MasterNode的StopFlag设置为false并对其管理的所有的线程调用void SetStopFlag()。

void run()
首先调用Register函数向master注册，如果注册失败，退出，如果注册成功，启动HeartBeatSender和TaskListener两个线程。

5.2 HeartBeatSender

5.2.1 overview

HeartBeatSender主要是用于不断向master发送心跳，使得master一直知道当前slave处于活动状态，当发现master拒绝slave的心跳时，关闭客户端。

5.2.2 构造函数

HeartBeatSender(SlaveNode s)
传递管理其的SlaveNode，设置stopFlag为false。

HeartBeat()
这个函数是进行一次心跳，如果成功，返回true，否则返回false。首先，如果无法连接上socket，则返回false。如果master返回值不是“OK”则打印返回值到logger并且返回false。

5.2.3 公有函数

void SetStopFlag()
把StopFlag设置为true，但自己永远不调用，只由SlaveNode线程调用。

void run()
不断进行心跳，如果HeartBeat函数调用返回false则关闭slave。

5.3 TaskListener

5.3.1 overview

TaskListener是用于处理任务的线程，其工作原理是建立socket等待master发送任务，当接受到master的任务过后，补全处理任务所需要的文件，然后计算，上传结果和文件，所有任务结束后接着等待下一次任务。

5.3.2 构造函数

TaskListener(SlaveNode s)
传递管理其的SlaveNode，设置stopFlag为false。

5.3.3 公有函数

void SetStopFlag()
把stopFLag设置为true。

boolean submit(String filename, String newname)
上传sandbox文件中名为filename的文件，并告知master把这个文件保存并命名为newname，当出现错误的时候返回false，否则返回true。

boolean cp(Sqtring orgname, String servername, String newname)
把本地名为orgname的文件拷贝到sandbox中，并命名为newname。当本地丢失orgname的文件时，向master请求名为servername的文件并重新命名为orgname。否则，继续拷贝。当出现任何问题是，返回false，否则，返回true。

boolean report(String dir)
把sandbox中名为dir文件里面的评测结果报告给master，如果出错，返回false。
boolean DoTask (ArralList¡String¿ data, int insize, int outsize)
这个函数的作用是处理一次任务，insize代表输入文件的个数，outsize代表输出文件的个数，data前insize个文件名是评测输入文件名，后outsize是处理后产生的文件名。注意前insize个文件的顺序可以打乱，但是outsize中的第一个必须是themis.out的输出文件，因为后面会对这个文件调用report函数函数运行时，首先，重新创建sandbox文件夹，准备好评测环境。接着调用cp函数把需要评测的文件拷贝到sandbox文件夹中。对sanbox调用make，接着把outsize个文件依次调用submit传输给master，最后调用report告知master评测完成。

void run()
首先TaskListener会注册一个ServerSocket用来等来master的任务。当收到任务后，调用DoTask处理任务，如果出现异常，关闭整个slavenode，否则，等待下一次任务。